

多模态数据治理平台 - 用户手册

产品介绍

平台简介

欢迎使用多模态数据治理平台。本平台面向 GenAI 应用，提供一站式、全流程数据生命周期管理能力。它系统性地解决多模态（文本、图片、音视频等）数据在进入 AI 模型训练与应用前，所面临的数据接入、处理、清洗、增强和管理等挑战。通过自动化的工作流编排，平台将复杂的数据准备工作流水线化，帮助用户高效构建高质量、AI 就绪（AI-Ready）的数据集，为大模型精调、AI 应用开发和数据价值挖掘奠定坚实的数据基础。

核心价值与解决方案

解决的核心痛点：

- 数据孤岛问题：**企业内部数据分散在不同系统，格式各异，难以统一管理和利用
- 数据质量参差不齐：**原始数据存在噪声、重复、缺失等问题，无法直接用于 AI 训练
- 数据处理复杂度高：**多模态数据处理需要不同的技术栈，人工处理效率低下
- 缺乏标准化流程：**数据从接入到可用缺乏标准化、可复用的处理流程

提供的解决方案：

- 统一数据接入：**通过连接器机制，支持多种数据源的标准化接入
- 自动化数据处理：**提供可视化工作流，实现数据解析、清洗、增强的自动化处理
- 质量保障体系：**内置数据清洗和增强能力，确保输出数据的高质量
- 数据资产管理：**提供完整的数据集生命周期管理，支持版本控制和血缘追踪

目标用户

本平台主要服务于以下用户：

- **数据工程师**：负责将海量、多源、异构的数据接入平台，并通过编排工作流完成数据的标准化、清洗和初步处理
- **AI/大模型开发工程师**：利用平台处理好的数据，通过数据增强、筛选、版本管理等功能，构建用于模型精调或训练的高质量数据集
- **业务分析师**：使用平台产出的数据集，进行业务分析和决策支持
- **应用开发工程师**：直接使用平台产出的数据集，开发和部署上层的 GenAI 或传统 AI 应用

核心概念

在深入了解平台各项功能前，建议先掌握以下核心概念：

数据流转的核心阶段

平台的整体工作流程可概括为三个主要阶段：数据接入 → 工作流处理 → 数据集管理。

1. 数据接入（Data Ingestion）

- **连接器（Connector）**：平台与外部数据源（如对象存储、HDFS）进行通信的接口，封装了访问数据源所需的地址、密钥等凭证信息
- **数据载入（Data Loading）**：具体的执行任务。使用已配置的连接器的，根据设定的策略（一次性或周期性），将外部原始文件拉取至平台的源数据目录

2. 工作流处理（Workflow Processing）

- **工作流（Workflow）**：平台进行自动化数据处理的核心引擎。由多个功能节点组成的可视化数据处理流水线，定义了数据从输入到输出的完整处理逻辑
- **节点（Node）**：工作流中的独立处理单元，负责执行一项具体的数据操作。主要节点包括：
 - **解析节点**：对原始文件进行内容提取（如从 PDF 中提取文本与图片，从音频中提取语音转文本）
 - **数据清洗节点**：对解析后的数据进行去重、过滤、格式化等操作，以提升数据质量
 - **数据增强节点**：利用大模型能力，将清洗后的数据加工成面向特定 AI 任务（如问答、分类）的格式化数据集
- **作业（Job）**：工作流的一次运行实例。每当工作流被触发执行，系统便会生成一个作业，用以记录该次运行的全部元数据、日志和结果

3. 数据管理（Data Management）

- **数据目录 (Data Catalog)**：平台内用于统一管理和浏览所有数据资产的视图，分为两类：
 - **源数据目录**：存放通过数据载入任务从外部拉取的原始文件
 - **目标数据目录**：存放经过工作流处理后生成的结构化、高质量数据
- **卷 (Volume)**：在数据目录中，用于实际存储数据的逻辑单元
- **数据集 (Dataset)**：平台数据处理流程的最终产物。从目标数据目录中选取数据、经过进一步组织和版本化管理后，最终可供模型训练或 AI 应用直接使用的、AI 就绪的数据集合

数据处理流程示例

一个典型的数据处理流程如下：

1. **数据接入**：通过连接器从对象存储中载入 PDF 文档到源数据目录
2. **工作流处理**：
 - **文本解析节点**：从 PDF 中提取文本内容并进行分段
 - **数据清洗节点**：去除重复内容、标准化格式
 - **数据增强节点**：利用大模型生成问答格式的训练数据
3. **数据集管理**：将处理后的数据组织成数据集，支持版本管理和导出

首次登录与界面导览

在您获得管理员分配的账户后，即可登录平台。平台主界面通常由以下几个部分构成：

- **左侧导航栏**：平台的核心功能入口。可切换至【数据连接】、【工作流】、【平台管理】等不同模块。
- **顶部状态栏**：包含当前登录用户信息、帮助文档入口和退出登录等功能。
- **主工作区**：页面核心区域，用于展示列表、配置表单、工作流画布和数据内容等。大部分操作将在此区域完成。

角色与权限说明

平台采用基于角色的访问控制（RBAC）机制，结合组织架构，实现精细化的权限管理。用户在被分配到特定组织后，会被授予一个角色，该角色决定了其在该组织空间内的操作权限。您的可用功能取决于组织管理员为您分配的角色。

主要内置角色包括：

- **管理员 (Manager)**：负责组织与成员的管理，并对组织内的数据资产拥有完全控制权。

- **开发者（Developer）**：负责数据的处理与数据集的构建，拥有组织空间的应用读写权限
 - **成员（Member）**：负责使用和查阅已处理好的数据成果，拥有组织空间中发布应用的使用权限
-

快速上手

概述

本章节将通过一个完整的示例，帮助您快速了解平台的主要功能和操作流程。我们将演示如何从数据导入到最终生成可用数据集的完整过程。

准备工作

在开始之前，请确保：

- 您已经拥有平台账号并完成登录
- 您的角色具有相应的操作权限（例如开发者角色）
- 准备好要处理的数据文件

完整操作流程

第一步：配置数据源连接

1. 进入【数据连接】→【连接器】页面
2. 点击【+ 创建连接器】按钮
3. 填写连接器基本信息：
 - **连接器名称**：输入便于识别的名称，如"测试数据源"
 - **数据源类型**：选择您的数据存储类型（对象存储或 HDFS）
4. 配置连接信息（根据您选择的数据源类型填写相应参数）
5. 点击【测试并创建】验证配置正确性，完成连接器创建

第二步：导入数据

1. 进入【数据连接】→【数据载入】页面
2. 点击【+ 创建数据载入任务】
3. 配置载入任务：
 - **任务名称**：输入任务名称，如"首次数据导入"
 - **绑定连接器**：选择刚才创建的连接器
 - **载入形式**：选择"单次载入"
 - **数据卷**：选择数据存储位置
4. 点击【确认】后自动启动数据载入任务
5. 在任务列表中查看载入进度，等待任务完成

第三步：创建数据处理 workflow

1. 进入【workflow】页面，点击【+ 创建工作流】
2. 在 workflow 设计器中构建处理流程：
 - 初始模版包含了【开始节点】、【解析节点】、【数据清洗节点】、【数据增强节点】、【结束节点】
 - 可根据需要自行删除或添加
3. 配置各节点参数：
 - 点击节点进入配置页面
 - 根据实际需求调整参数设置
4. 点击【上线】将 workflow 发布

第四步：执行数据处理

1. 在 workflow 详情页点击【运行】按钮
2. 系统会自动创建并启动作业
3. 进入【作业】页面查看运行状态
4. 点击作业名称可查看详细的运行日志和进度

第五步：管理处理结果

1. 作业完成后，进入【数据管理】→【数据目录】→【目标数据】
2. 查看 workflow 处理后生成的结构化数据

3. 进入【数据管理】→【数据集管理】页面

a. 点击【+ 新建数据集】，基于处理结果创建数据集：

- 填写数据集名称、标签、描述等基本信息
- 选择数据来源
- 预览数据内容
- 完成数据集创建

b. 可以对数据集进行导出、版本管理等操作

后续步骤

完成快速上手后，建议您：

- 详细阅读各模块的使用说明，了解更多高级功能
- 根据实际业务需求，探索不同的数据处理节点和配置选项
- 学习使用权限管理功能，建立团队协作机制

💡 提示：整个流程大约需要 15-30 分钟完成，具体时间取决于数据量大小和处理复杂度。

数据接入

简介

数据接入是平台所有数据处理流程的起点。该模块负责将企业内部或外部数据源（如对象存储、HDFS）中的原始数据，安全、高效地拉取至平台内统一存储，为后续的数据解析、清洗、增强及数据集管理提供基础。

本模块主要包含两大核心功能：

- **连接器管理**：配置并管理与各类外部数据源（如对象存储 S3、HDFS）的连接凭证。
- **数据载入管理**：创建并监控数据载入任务，将数据从源端抽取至平台。

连接器管理

连接器是平台与数据源之间进行通信的必要配置。在载入任何数据之前，必须首先创建一个连接器。

连接器列表页

进入【数据连接】->【连接器】菜单，您将看到连接器列表页。此页面集中展示了所有已创建的连接器。

- **连接器名称：**您为连接器设定的名称。点击名称可进入详情页。
- **状态：**
 - ● 已连接：平台当前可成功访问该数据源。
 - ● 已断开：连接信息失效或网络不通，无法访问。
- **数据源类型：**目前支持对象存储和 HDFS。
- **创建人 / 创建时间 / 更新时间：**连接器的审计信息。
- **操作：**
 - **详情：**查看该连接器的详细配置信息。
 - **编辑：**修改连接器的配置。
 - **删除：**永久删除该连接器。

⚠ 警告：删除一个连接器会立即终止所有正在使用该连接器的数据载入任务（包括一次性和周期性任务），并可能导致任务失败。此操作不可逆，系统会弹出二次确认框防止误删。

创建连接器

1. 在连接器列表页，点击右上角的 **[+ 创建连接器]** 按钮，弹出创建窗口。
2. 根据您的数据源类型，填写连接信息。
 - **连接器名称：**建议采用能清晰表达业务、数据源和用途的规范名称。
 - **连接器类型：**选择对象存储或 HDFS。
 - **连接信息（以对象存储为例）：**
 - **Endpoint：**对象存储的访问地址。
 - **AccessKey ID / Secret：**访问对象存储的密钥对。
 - **文件路径：**指定要访问的 Bucket 名称，格式为 `<桶名>`。如需限制在桶内某个目录下，可填写 `<桶名>/<目录前缀>`。

3. 填写完毕后，点击 **[测试并创建]** 按钮。系统会验证连接信息的有效性。
 - **验证成功**：提示“测试链接成功”，并自动保存连接器，返回列表页。
 - **验证失败**：提示“连接失败”及具体的错误原因，请根据提示检查您的配置。
4. 点击 **[取消]** 将放弃本次创建。

编辑连接器

在连接器列表的操作列中点击 **[编辑]**。

- 只能修改“连接信息”部分，连接器名称与类型不可更改。
- 修改后，点击 **[测试并创建]** 即可。

 **说明**：保存新的连接信息后，正在使用此连接器的运行中任务不会中断。对于周期性任务，系统将在下一次调度运行时自动采用新的连接信息。

数据载入管理

当连接器创建成功后，您便可以创建数据载入任务，将数据正式拉取到平台中。

载入任务列表页

进入【数据连接】->【数据载入】菜单，您将看到载入任务列表页。

- **载入任务名称**：您定义的任务名称，点击可进入任务详情页。
- **载入形式**：单次载入或周期载入。
- **最近运行状态**：
 -  **运行成功**：任务已按计划成功执行。
 -  **运行失败**：任务执行时发生错误。失败的周期任务将不再被自动调度。
 -  **运行中**：任务当前正在执行。
- **数据源类型 / 连接器名称**：任务使用的数据源及连接器。
- **载入位置**：数据在平台内的存储路径。
- **操作**：
 - **详情**：查看任务的详细配置和运行历史。
 - **编辑**：修改任务配置。正在运行的任务不允许编辑。
 - **删除**：永久删除该任务。此操作会停止正在运行的实例，但不会删除已载入平台的文件。

创建数据载入任务

1. 在数据载入列表页，点击右上角的 **[+ 创建数据载入任务]** 按钮。
2. 在弹出的窗口中填写任务信息：
 - **任务名称**：为任务命名。
 - **数据源类型**：选择后，“绑定连接器”下拉框会自动筛选出对应类型的可用连接器。
 - **绑定连接器**：选择一个已创建好的连接器。
 - **载入形式**：
 - **单次载入**：任务创建后仅执行一次，载入源端当前全部文件。
 - **周期载入**：根据设定周期性执行。首次为全量载入，后续为增量载入。
 - **载入位置**：点击下拉框，选择数据在平台内存储的卷（Volume）。
3. 点击 **[确认]** 完成创建，新任务将出现在列表页。

查看任务详情与运行历史

点击任务列表中的任意一个 **[载入任务名称]**，即可进入任务详情页面。该页面是监控和排查问题的核心。

页面包含两部分：

- **任务信息**：显示该任务的所有静态配置信息。
- **运行历史**：记录了该任务的每一次执行情况（单次任务只有一条，周期任务有多条）。
 - **运行 ID**：每次运行的唯一标识。
 - **状态**：当次运行的最终状态（成功/失败）。
 - **开始时间 / 结束时间**：当次运行的起止时间。
 - **详情**：
 - **运行成功**：显示成功和失败的文件数。
 - **运行失败**：显示具体的错误日志信息。
 - 可点击“详情”，进一步查看本次运行中每一个文件的详细载入状态、处理耗时及失败原因，是排查数据问题的关键入口。

在该页面，还可点击 **[新建运行]** 按钮，手动触发一次任务执行。

编辑数据载入任务

在数据载入任务的详情页点击 **[编辑]** 按钮，进入任务编辑弹窗页面。

💡 说明：对于周期性运行的任务，修改从下一次运行开始生效。

运行详情页面

点击运行历史中的"更多信息"链接，进入运行详情页面。该页面包含两部分：

运行统计部分：

- **总文件数**：本次运行处理的文件总数
- **成功文件数**：成功载入的文件数量
- **失败文件数**：载入失败的文件数量
- **处理耗时**：本次运行的总耗时

文件详情部分：

以表格形式展示每个文件的详细处理情况：

- **文件名**：被载入的文件名称
- **状态**：文件载入状态（成功/失败）
- **类型**：文件类型（如 PDF、TXT、JPG 等）
- **开始处理时间**：开始载入该文件的时间
- **处理结束时间**：完成载入该文件的时间
- **详细信息**：如果文件载入失败，此处显示具体的错误信息

产品使用限制

在使用数据接入功能时，请注意以下系统限制：

性能限制

- **最大并发任务数**：系统同一时间最多支持 128 个数据载入任务运行。
- **单次任务文件数上限**：每个任务单次执行最多能加载 65,536 个文件。
- **单文件大小上限**：加载的单个文件大小不能超过 2GB。

文件去重机制

平台通过文件名来区分文件。当重新启动一个任务时，如果某些文件已经被加载，则重新启动的任务不会加载同名的文件，避免重复载入。

工作流与作业管理

功能概述

数据接入模块实现了数据的输入，而工作流模块则是实现数据自动化处理与价值提炼的核心引擎。它将接入的原始数据，通过一系列可编排的处理节点，系统性地转化为结构化、高质量的 AI 就绪（AI-Ready）数据。

本模块的核心概念如下：

- **工作流（Workflow）**：一个可视化的数据处理蓝图。用户通过拖拽和配置功能节点来设计数据处理流水线，定义了数据处理的逻辑与步骤。
- **作业（Job）**：工作流的一次具体执行实例。每当工作流被触发，系统都会创建一个作业来记录该次运行的全过程，包括状态、日志、耗时和结果。

本模块的功能主要分为两大部分：

- **工作流管理**：设计、配置和维护数据处理流水线。
- **作业管理**：监控和审查每条流水线的具体执行情况。

工作流管理

工作流列表页

进入左侧导航栏的【工作流】，您将看到平台中所有已创建的工作流。

- **名称**：工作流的唯一名称，点击可进入详情页。
- **源数据目录 / 目标数据目录**：显示该工作流处理的数据来源与产出位置。
- **处理状态**：
 - **完成**：最近一次执行已成功结束。
 - **运行中**：工作流当前正在执行一个作业。
 - **等待调度**：周期性任务，正在等待下一个执行时间的到来。

- **失败**：最近一次执行失败。失败的周期性工作流将不再被自动调度。
- **运行方式**：一次运行或周期运行。
- **操作**：
 - **详情**：进入工作流的配置画布页面，可进行工作流的编辑、运行工作流
 - **复制**：快速创建一个与当前工作流配置完全相同的新工作流，便于进行微调和实验。
 - **删除**：永久删除工作流。如果工作流正在运行，会先终止其作业再删除。

创建新工作流

在列表页点击 **[+ 创建工作流]** 按钮，进入工作流设计页面。创建过程主要分为两步：

第一步：配置基本信息

- **名称**：为工作流命名。
- **源数据目录**：指定工作流要处理的数据来源，可选择一个或多个源数据卷。
- **目标数据目录**：指定工作流处理完成后，数据的存放位置，只能选择一个目标数据卷。
- **处理数据类型**：指定该工作流主要处理的文件类型（如文本、图片、音频、视频）。此选项会影响下一步中可选的解析节点类型。
- **运行频率**：一次运行或周期运行。

第二步：设计工作流拓扑结构

- **起始节点与结束节点**：分别代表第一步中选择的源数据目录和目标数据目录。
- **添加节点**：点击起始节点或已有节点上的"+"号，选择添加新的处理节点。

工作流节点类型详解

1. 起始节点

起始节点是个工作流必须的起点，系统自动创建。该节点显示工作流需要处理的数据来源信息，包括源数据目录和数据卷名称，以及将要处理的数据格式类型。

2. 数据解析节点

数据解析节点是工作流处理的核心组件，负责从原始文件中提取有价值的信息并转换为结构化数据。根据处理的数据类型，平台提供四种解析节点：

2.1 文本解析节点

文本解析节点专门用于处理文本格式的原始文件，将其解析成结构化的数据集。该节点支持多种文本格式，包括 TXT/MD 纯文本文件、PDF 文档、DOC/DOCX 文档、PPT/PPTX 演示文稿等。

主要配置参数：

- **节点名称：**为节点指定一个描述性的名称，便于工作流管理和监控。
- **文件选择：**系统会自动列出源数据目录中的所有文本类型文件，默认全选。用户可根据需要取消选择不需要处理的文件。
- **文本分段配置：**
 - **分段方式：**支持按字符、句子、段落三种方式对文本进行切分。
 - **分段最大长度：**当选择按字符分段时，需要指定每个分段的最大字符数（默认 800 字符）。
- **文本处理规则：**
 - **替换标点和特殊字符：**选择是否需要将文本中的标点符号和特殊字符进行标准化处理。
 - **删除有效 URL 和邮箱地址：**选择是否需要移除文本中的网址链接和电子邮件地址。
- **模型选择：**
 - **文本嵌入模型：**指定对文本内容进行向量化处理的嵌入模型（如 Qwen3-Embedding-8B）。

2.2 图片解析节点

图片解析节点专门处理图像文件，能够从图片中提取文本信息并生成结构化数据。该节点支持常见的图片格式，如 JPG、PNG、GIF 等。

主要配置参数：

- **节点名称：**为节点设置描述性名称。
- **图片文件选择：**系统自动列出源数据目录中的所有图片文件，默认全选。用户可根据需要进行筛选。
- **图片描述模型：**选择用于生成图片描述文本的 AI 模型（如 Qwen2.5-VL-72B-Instruct）。
- **图片嵌入模型：**选择用于将图片描述转换为向量表示的嵌入模型（如 Qwen3-Embedding-8B）。

2.3 音频解析节点

音频解析节点专门处理音频文件，将语音内容转换为文本信息。该节点支持多种音频格式，并提供丰富的音频处理和语音识别功能。

主要配置参数：

- **节点名称：**为节点设置描述性名称。
- **音频文件选择：**系统自动列出源数据目录中的所有音频文件，默认全选。
- **音频预处理：**
 - **降噪处理：**选择是否对音频进行降噪处理，提高语音识别准确度。
 - **语音增强：**选择是否启用语音增强功能，优化音频质量。
- **语音活动检测（VAD）与切片设置：**
 - **启用语音活动检测：**系统可自动检测音频中的有效语音段落，过滤静音部分。
 - **切片模式：**
 - **自动切片：**系统根据语音活动检测结果自动分割音频。
 - **固定时长切片：**按照指定的时间长度（秒）对音频进行均匀切分。
- **说话人识别：**
 - **启用多说话人识别：**当音频中包含多个说话者时，系统可区分不同说话人并在结果中标记。
 - **说话人标识：**解析结果将按说话人进行分组，便于后续的对话分析。
- **解析模型选择：**
 - **音频解析模型：**选择语音转文本的 AI 模型（如 Qwen2.5-Omni-7B）。不同模型在准确性和处理速度方面有所差异，用户可根据实际需求选择。
- **后处理与校验：**
 - **启用后处理：**对转换后的文本进行格式化和标准化处理。
 - **使用大模型进行错别字校验：**利用大语言模型对转换结果进行错误检查和纠正。
 - **文字标准化：**对输出文本进行格式统一和规范化处理。
- **节点说明：**对该节点功能和配置的详细说明。

2.4 视频解析节点

视频解析节点专门处理视频文件，能够同时提取视频中的音频信息和视觉信息，并将其转换为结构化的文本数据。

主要配置参数：

- **节点名称：**为节点设置描述性名称。
- **视频文件选择：**系统自动列出源数据目录中的所有视频文件，默认全选。
- **字幕与音频校验：**
 - **多音轨解析：**当视频包含多个音轨时，可选择解析所有音轨并进行内容合并。
 - **开启降噪处理：**选择是否对音频进行降噪处理，提高语音识别准确度
- **语音活动检测（VAD）与切片设置：**
 - **启用语音活动检测：**自动检测视频中的有效语音段落。
 - **启用多说话人识别：**区分视频中的不同说话者。
 - **切片模式：**支持自动切片和固定时长切片两种模式。
- **解析模型选择：**
 - **音频解析模型：**选择适合的语音转文本模型（如 Qwen2.5-Omni-7B）。
- **后处理与校验：**
 - **使用大模型进行错别字校验：**利用 AI 模型进行文本校验和纠错。
 - **文本标准化：**对输出进行格式标准化处理。

⚠ 注意：字幕文件与音频文件校对功能在当前版本中暂不支持，将在后续版本中提供。

3. 数据清洗节点

数据清洗节点负责对解析节点输出的数据进行质量提升和标准化处理。该节点通过多种清洗规则的组合应用，能够有效去除噪声数据、标准化格式、填补缺失信息，为后续的数据增强处理奠定高质量的数据基础。

主要配置参数：

- **节点名称：**为节点设置描述性名称。
- **数据清洗类型选择：**平台提供多种数据清洗操作，用户可根据数据特点选择适合的清洗规则：
 - **数据标准化：**将数据转换为标准格式或单位。
 - **数据过滤：**根据规则过滤数据，去除无效、错误或低质量数据。
 - **特殊字符删除：**去除 URL 链接、去除不可见字符、去除 html 格式字符
 - **去除敏感词：**识别并过滤掉包含敏感、负面或不当内容的词汇，如辱骂性语言、极端情绪表达等，确保数据内容的健康性和合规性

- **数据去毒化**：检测并移除涉及违法、有害、危险内容的数据，如爆炸物制作方法、恶意攻击指南等，保障数据安全和合法性
- **数据填补**：填补缺失数据或不完整的数据记录，可以使用默认值、统计值或特定标记（如"?"）来替代空缺信息。
- **异常值处理**：识别和处理数据中的异常值，通过统计分析方法检测超出正常范围的数值并进行移除或修正，提升数据质量的一致性。

 提示：数据清洗是提高数据质量的关键环节。建议先对小批量数据进行测试，确认清洗效果后再应用到完整数据集。

4. 数据增强节点

数据增强节点是工作流的高级处理组件，利用大语言模型的能力，将清洗后的数据转换为面向特定 AI 应用场景的高质量、精调就绪（Finetune-Ready）数据集。

4.1 数据增强核心理念

在大语言模型（LLM）应用中，数据增强是指利用现有少量高质量种子样本，通过规则或模型自动生成更多多样化但语义等价或相关的训练样本，以放大数据规模、覆盖场景边界、提升模型泛化与鲁棒性的过程。

4.2 主要配置参数

- **节点名称**：为节点设置描述性名称。
- **核心参数配置**：
 - **应用场景选择**：根据目标 AI 应用选择相应的数据增强场景：
 - **通用**：适用于大多数 SFT 微调场景的数据集生成
 - **文本分类**：针对文本分类任务优化的数据增强
 - **文本提取**：专门用于信息抽取任务的数据生成
 - **文本生成**：面向文本生成任务的样本扩充
 - **多轮回答**：支持多轮对话场景的数据增强

每种场景都会自动配置相应的提示词模板和生成策略。

- **指令生成依赖样本数**：设置用作参考模板的样本数量。系统会从您现有的数据中挑选指定数量的样本作为生成新数据的参考范例

- **任务描述增强占比**：此参数控制AI对原始数据进行同义改写的比例，以生成表述更多样的数据，从而提升模型泛化能力和最终效果
- **过滤相似度阈值**：通过 Rouge-L 分数计算生成训练数据集的相似度，超过阈值的数据被认为是重复的，只保留其中之一。
- **生成样本数**：设置要新创建的数据条数。这是纯新增的数据量，不包含您原有的数据。例如设置为 100，就会为您新生成 100 条数据。
- **数据示例（JSON 格式）**：系统会以 JSON 格式展示生成数据的结构示例，包含 instruction、context、response 等字段，帮助您了解最终输出格式。
- **自定义提示词**：勾选此选项可以自定义数据生成的提示词模板，适用于有特殊格式要求或领域特色的场景。
- **模型选择**：选择用于数据增强的大语言模型。

4.4 实际应用示例

以通用问答场景为例，输入种子数据：

代码块

```
1  {
2    "id": "1",
3    "context": "杭州是浙江省的省会，杭州位于浙江省的东部，占地面积xxx平方公里"
4  }
```

经过数据增强后，可能生成：

代码块

```
1  {
2    "instruction": "杭州的基本地理信息是什么？",
3    "context": "杭州是浙江省的省会，杭州位于浙江省的东部，占地面积xxx平方公里",
4    "response": "杭州是浙江省省会城市，地处浙江省东部地区，总占地面积为xxx平方公里。",
5    "source_ids": ["1"]
6  }
```

💡 最佳实践建议：

1. **合理设置生成数量**：建议从小批量开始测试，确认效果后再扩大规模。
2. **调整相似度阈值**：根据具体需求调整过滤阈值，平衡数据多样性和质量。
3. **优化提示词**：根据领域特点定制提示词，提高生成质量。

5. 结束节点

结束节点是个工作流的终点，系统自动创建。该节点显示工作流处理完成后，数据的最终存储位置，包括目标数据目录和数据卷信息。

产品使用限制

- **节点数量限制：**每个工作流最多支持 16 个同类型的解析节点。
- **数据清洗节点限制：**当前版本每个工作流最多包含 1 个数据清洗节点。
- **数据增强节点限制：**当前版本每个工作流最多包含 1 个数据增强节点。
- **文件处理限制：**
 - **文本解析节点：**单个文件最大 2GB，最多处理 65,536 个文件。
 - **图片解析节点：**单个文件最大 128MB，最多处理 65,536 个文件。
 - **音频解析节点：**单个文件最大 2GB，最多处理 4,096 个文件。
 - **视频解析节点：**单个文件最大 2GB，最多处理 4,096 个文件。

 说明：随着产品功能的持续完善，节点兼容性表格和限制条件可能会在后续版本中进行调整和优化。

作业管理

作业是工作流的执行记录，是监控和排查问题的关键入口。

作业列表页

进入左侧导航栏的【作业】（或【数据处理】->【作业】），您将看到所有作业的列表。

- **作业 ID：**系统为每次作业生成的唯一标识。
- **作业名称：**作业的名称
- **状态：**完成、运行中或失败。
- **开始时间 / 结束时间 / 运行时长：**作业的生命周期计时。
- **工作流名称：**表明该作业是由哪个工作流产生的。

作业详情页

点击任一作业 ID 或名称，即可深入查看该次执行的完整详情。页面包含三部分：

- **作业基本信息：**作业的状态、用时、开始结束时间等基本信息
- **workflow 拓扑结构：**展示本次作业运行时所使用的工作流快照。即使工作流后续被修改，这里依然显示当时执行的版本。
- **执行详情：**分节点展示详细的执行情况。
 - **文本解析：**显示每个文件的处理状态、开始/结束时间、成功或失败信息。
 - **数据清洗：**
 - **清洗统计：**宏观展示各类清洗规则影响了多少行数据。
 - **规则应用情况：**详细列出每条清洗规则的执行情况和结果。
 - **数据增强：**展示增强前后的数据记录条数对比，以及详细的执行日志。

通过分析作业详情，您可以精确定位数据处理流程中可能出现的任何问题，无论是单个文件解析失败，还是某条清洗规则配置不当。

数据管理

简介

数据管理是平台数据处理流程的最后一个环节，也是用户获取最终 AI 就绪数据的关键模块。该模块将工作流处理后的数据进一步加工成为可以面向精调、AI 应用相关的数据集，提供完整的数据集生命周期管理能力。

数据集管理模块主要包含两大核心功能：

- **数据目录：**统一管理和浏览平台内的所有数据资产，包括源数据和处理后的目标数据。
- **数据集管理：**创建、编辑、版本控制和导出 AI 就绪的数据集。

数据目录管理

数据目录是平台内用于统一管理和浏览所有数据资产的视图，为用户提供了数据的全景视图和血缘关系。

源数据目录

源数据目录用于展示通过数据载入任务加载到系统中的原始文件。

源数据目录列表页

进入【数据管理】→【数据目录】→【源数据】，您将看到所有原始数据文件的列表。

列表信息解读：

- **文件名：**载入的原始文件名称。
- **文件类型：**显示文件的格式类型（如 PDF、DOCX、TXT 等）。
- **文件大小：**该原始文件的大小。
- **上传用户：**该文件是通过哪个用户创建的载入任务上传的。
- **载入开始时间：**文件被载入到系统中的时间。
- **连接器名称：**指定该文件是通过哪个连接器加载进来的。

操作功能：

- **导出：**将该文件导出到指定的对象存储位置。
- **删除：**删除该文件。支持批量删除操作。

目标数据目录

目标数据目录用于展示经过工作流处理后产生的结构化数据。

目标数据目录列表页

进入【数据管理】→【数据目录】→【目标数据】，您将看到所有处理后数据的列表。

列表信息解读：

- **ID：**用于区别每一行数据的唯一标识。
- **数据内容：**显示数据的内容。
- **生成时间：**该行数据被生成的时间。
- **其他信息：**显示数据的血缘关系信息，包括：
 - 对应的原文件名

- 产生这行数据的工作流 ID
- 原文件类型：原文件的数据类型

操作功能：

- **导出：**将数据导出到指定位置。
- **删除：**删除该数据记录。支持批量删除操作。

数据集管理

数据集是平台数据处理流程的最终产物，是从目标数据目录中选取数据、经过进一步组织和版本化管理后，最终可供模型训练或 AI 应用直接使用的数据集合。

数据集列表页

进入【数据管理】→【数据集】，您将看到所有数据集的概览信息。

列表信息解读：

- **数据集名称：**创建该数据集时指定的名字。点击名称可进入数据集详情页。
- **标签：**用于标识该数据集的标签信息，方便用户在多个数据集中快速找到需要的数据。
- **版本：**显示该数据集的版本号。
- **状态：**数据集当前的状态，包括：
 - **正常：**数据集可正常使用，支持所有操作。
 - **创建中：**正在创建数据集，此状态下不可进行其他操作。
 - **创建失败：**数据集创建失败，仅可删除。点击状态可查看错误信息并重试。
 - **版本更新中：**正在生成新版本，可查看详情和导出，不可编辑和删除。
 - **版本更新失败：**版本更新失败，可查看错误信息并重试。
- **描述：**数据集的描述信息。
- **生成模型：**生成该数据集时所使用的模型（仅当数据集通过数据增强节点生成时显示）。
- **创建人：**创建该数据集的平台用户。
- **创建时间：**数据集创建的时间。
- **最近更新：**数据集最近一次更新的时间。

操作功能：

- **导出：**将数据集导出到指定连接器。
- **删除：**永久删除数据集。

创建数据集

点击【+ 新建数据集】按钮，进入数据集创建页面。

创建步骤：

1. 基本信息配置

- **名称：**自定义数据集名称，建议使用有意义的命名。
- **标签：**可以选择系统已有的标签，或者自定义标签。
- **描述说明：**输入对数据集的详细描述和说明信息。

2. 数据来源选择

- **数据来源：**可以从目标数据目录的卷或者某个连接器中选择创建数据集的数据来源。
- **文件选择：**系统会列出所选数据源中的所有可用文件，用户可以选择需要的文件。

3. 数据预览

- **文件内容预览：**点击预览按钮，可以查看数据预览以及部分示例行（默认显示前 50 行）。
- **数据格式确认：**确认数据格式是否符合预期。

4. 完成创建

- 点击【确定】按钮，系统开始处理所选文件，并生成对应的数据集。
- 页面返回数据集列表页，可以查看创建进度。

数据集详情页

点击数据集名称进入详情页面，可以查看数据集的完整信息。

基本信息区域

显示数据集的核心信息：

- **数据集名称**：如"dataset1"
- **当前版本**：显示数据集的当前版本号
- **标签**：显示数据集的所有标签
- **创建时间**：数据集被创建的时间
- **创建者**：如"admin"
- **更新时间**：数据集最近一次被更新的时间
- **生成模型**：显示生成该数据集的模型名称（仅当数据集通过数据增强节点产生时显示）
- **描述说明**：显示数据集的详细描述信息

版本历史

按时间顺序列出该数据集的所有版本及其备注信息。每条版本记录包含：

- **版本号**：版本的唯一标识
- **修改类型**：
 - **数据导入**：通过数据接入、工作流处理等方式新增数据到数据集
 - **用户手动修改**：用户通过界面直接编辑、删除或新增数据记录
- **创建时间**：版本创建的时间
- **变更记录**：详细描述本次版本变更的具体内容
 - 对于数据导入：显示"初始导入 X 条记录"或"新增导入 X 条记录"
 - 对于用户修改：显示具体的操作统计，如"修改了 X 条记录，总计 X 条记录"、"删除了 X 条记录，总计 X 条记录"等

版本对比功能：

1. 点击【数据集对比】按钮进入版本对比页面
2. 选择需要对比的两个版本
3. 点击【开始对比】查看版本差异
4. 系统会按照数据集中的 ID 列作为连接键，对每一行数据的内容进行对比
5. 可以通过【返回选择】重新选择对比版本，或点击【关闭】返回详情页

内容数据区域

显示数据集中的具体数据内容：

- **数据展示：**以表格形式展示数据集的所有内容
- **搜索过滤：**通过查询框对数据内容进行过滤
- **行级操作：**可以删除单行数据

数据编辑功能：

1. 点击【编辑数据】进入编辑模式
2. 可以修改每一行的数据内容
3. 可以删除不需要的数据行
4. 点击【确定】提交编辑，系统会生成新的数据集版本
5. 由于版本生成需要时间，提交后会返回列表页，数据集状态显示为"版本生成中"

数据集导出

用户可以将数据集导出到指定的连接器，方便在其他系统中使用。

导出步骤：

1. 在数据集列表页点击【导出】按钮
2. 在导出设置页面配置导出参数：
 - **连接器名称：**选择目标连接器
 - **导出文件路径：**指定导出文件的存储路径
3. 点击【确定】开始导出
4. 导出任务是异步执行的，完成后会显示提示信息

数据集删除

删除数据集是不可逆操作，需要谨慎执行。

产品使用限制

在使用数据集管理功能时，请注意以下系统限制：

数据类型限制

- **支持的数据类型：**目前仅支持文本类型的数据集
- **暂不支持：**图片、音频、视频或其他复杂格式

数据容量限制

- **单个数据集大小：**不建议超过 50GB
- **超出限制的处理：**需要用户手工进行分片或归档处理

文件格式限制

- **支持的格式：**仅支持 JSONL 格式
- **数据结构：**每行为一个 JSON 对象

版本管理限制

- **版本保留数量：**默认仅保留最近 16 个数据集版本
- **版本清理：**更多版本需要手动清理或归档

权限限制

- **数据集管理员角色：**需要具有"数据集管理员"角色才能管理数据集
- **组织隔离：**不同组织的数据集相互隔离
- **操作权限：**根据用户角色确定具体的操作权限

平台管理

简介

平台管理模块是整个系统的后台控制中心，专注于身份与访问管理（IAM）。其核心目标是确保合适的用户，在合适的组织内，拥有恰当的权限，实现安全、可控、高效的团队协作和数据治理。

本模块通过组织架构和用户与角色管理两大功能，实现多层次的数据与资源隔离。您可以创建不同的组织（如按部门、项目或业务线划分），并将用户分配到特定组织，再通过预设的角色赋予其不同的操作权限。

主要功能包括：

- **组织管理**：创建和维护树状的组织结构，作为资源和用户的逻辑容器。
- **用户管理**：集中管理平台所有用户账户的生命周期（创建、启用、停用、删除）。
- **基于角色的访问控制（RBAC）**：为用户分配角色，精细化控制其对组织内资源的访问权限。

组织架构

组织架构是实现资源隔离和分级管理的基础。平台内的所有资源，如数据、工作流和数据集，都与特定的组织绑定。

功能概述

通过创建树状的组织结构，您可以模拟企业的真实部门层级。每个组织都是一个独立的工作空间，其内部成员和资源默认对其他组织不可见，从而保障了数据的安全性和私密性。

组织架构页面

进入左侧导航栏的【平台管理】->【组织架构】，您将看到组织管理界面。

- **左侧组织树**：以层级结构展示所有组织。可点击不同的组织，查看其下属的子组织和成员详情。
- **右侧成员列表**：展示当前选中组织内的所有成员信息。
 - **成员/账号状态**：显示用户的姓名、用户名及当前账户是“启用”还是“停用”状态。
 - **部门/角色**：显示用户所属的组织（部门）及其在该组织内被授予的角色。
 - **操作**：
 - **停用**：临时禁用该用户账户。用户将无法登录平台，但其数据和配置信息将被保留。可随时重新“启用”。
 - **删除**：永久移除该用户。此操作不可逆，请谨慎使用。

管理组织内成员

在指定组织的成员列表页，您可以进行以下操作：

- **添加成员**：点击 [+ 添加成员] 按钮，为当前组织快速添加新用户。

- **搜索成员：**在列表上方的搜索框中输入姓名或用户名，快速定位成员。

用户与角色管理

此功能提供了对平台所有用户账户的集中管理视图，并是进行用户创建和权限分配的核心入口。

成员管理页面

进入【平台管理】->【用户管理】，您将看到平台所有用户的列表。

- **筛选功能：**可根据“姓名”或“部门”进行筛选，快速查找用户。
- **列表信息解读：**展示用户的全局信息，包括姓名、状态、所属主部门、角色及创建时间。

创建新用户

在“成员管理”或“组织架构”页面点击 **[+ 添加成员]** 按钮，即可开始创建新用户。

- **姓名：**用户的真实姓名，用于显示。
- **用户名：**用户的登录凭证。规则：只能包含英文、数字和下划线，且必须以英文开头。
- **密码/确认密码：**设置用户的初始登录密码。规则：密码需包含 8-24 位字符，混合大小写字母、数字和符号，且不应包含个人信息。
- **手机号：**（可选）用户的联系方式。
- **所属组织：**为用户指定一个主组织。用户将被归入该组织的空间进行工作。
- **角色：**为用户选择一个角色，决定其在所属组织内的操作权限。
- **职位/备注：**（可选）补充用户的额外信息。

填写完毕后，点击 **[确定]**，用户账户即创建成功。新用户可以使用您设置的用户名和密码登录平台。

常见问题解答（FAQ）

平台基础问题

Q1：平台支持哪些数据类型？

A1：平台支持文本、图片、音频、视频等多种主流数据格式，具体包括

- 文本：PDF, PPT/PPTX, DOC/DOCX, TXT/MD
- 图片：JPEG, PNG, JPG
- 音频：WAV, MP3, AAC, FLAC
- 视频：MP4, MOV, MKV

Q2：如何保障数据安全？

A2：平台采用多层级权限控制，所有数据操作均有日志记录，支持组织级别的数据隔离和加密存储，确保数据安全可靠。

Q3：数据处理失败如何排查？

A3：平台为每个作业提供详细的运行日志和错误信息，用户可在作业详情中查看失败原因，并根据提示进行调整。

Q4：平台支持多用户协作吗？

A4：支持。平台具备完善的组织与权限管理机制，支持多用户、多组织协作，保障数据隔离与安全。

数据集管理问题

Q5：什么是数据集？与数据目录有什么区别？

A5：数据目录是平台内所有数据的管理视图，包括源数据和处理后的目标数据。数据集是从目标数据中选取、经过进一步组织和版本管理后，可直接用于 AI 训练的数据集合。

Q6：如何创建数据集？

A6：进入【数据管理】→【数据集】，点击【+ 新增数据集】，选择数据来源，配置基本信息，预览数据内容，最后点击【创建】即可。

Q7：数据集支持哪些格式？

A7：目前数据集仅支持 JSONL 格式，每行为一个 JSON 对象。暂不支持图片、音频、视频等复杂格式。

Q8：数据集有大小限制吗？

A8：单个数据集建议不超过 50GB。超出此限制需要手工进行分片或归档处理。

Q9：如何管理数据集版本？

A9：系统自动为数据集创建版本。每次编辑数据集内容后，系统会生成新版本。默认保留最近 16 个版本，可在详情页查看版本历史和进行版本对比。

Q10：如何导出数据集？

A10：在数据集列表页点击【导出】，选择目标连接器，设置导出路径和格式，点击【导出数据集】即可。导出是异步操作，完成后会有提示。

Q11：数据集可以删除吗？

A11：可以删除，但删除操作不可逆。删除后数据集及其所有版本将被永久删除，建议在删除前先导出重要数据。

Q12：为什么我看不到某些数据集？

A12：这可能是由于权限限制或组织隔离。不同组织的数据集相互隔离，用户只能看到自己组织内的数据集。

数据处理问题

Q13：工作流处理后的数据在哪里查看？

A13：进入【数据管理】→【数据目录】→【目标数据】，可以查看所有经过工作流处理后的数据。

Q14：如何查看数据的处理血缘？

A14：在目标数据目录中，每条数据的"更多信息"列会显示对应的原始文件名和产生该数据的工作流作业 ID。

Q15：数据集创建失败怎么办？

A15：点击数据集状态链接查看错误信息，根据提示检查数据源和配置，可以点击重试按钮重新创建。

技术支持问题

Q16：系统有哪些使用限制？

A16：主要限制包括：最大并发数据载入任务 128 个，单个文件大小不超过 2GB，单次任务文件数不超过 65,536 个，数据集版本保留 16 个等。

Q17：遇到系统问题如何获得支持？

A17：请联系平台管理员或技术支持团队，提供详细的操作步骤和错误信息，以便快速定位和解决问题。

联系与支持

如在使用过程中有任何疑问或建议，欢迎通过平台内反馈渠道或联系管理员获得帮助。我们致力于持续优化产品体验，感谢您的信任与支持。